SERVIÇO PÚBLICO FEDERAL
UNIVERSIDADE FEDERAL DE SERGIPE
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

TÓPICOS AVANÇADOS EM ENGENHARIA DE SOFTWARE E SI I

Atividade Avaliativa 1

Curadoria de Datasets e Inferência com LLMs no Domínio Médico

Relatório Individual

Análise das questões abertas 86–100 e das questões de múltipla escolha 136–162

Discente:	Gilson Inácio da Silva
Matrícula:	202611005730
Programa:	Pós-Graduação em Ciência da Computação
Equipe:	Equipe 2 - Medicina
Natureza do relatório:	Individual

São Cristóvão – SE
2026

Sumário

1 Introdução **2**

2 Objetivos **2**

2.1 Objetivo geral 2

2.2 Objetivos específicos 2

3 Bases de dados e escopo individual **3**

3.1 Dataset M1 - K-QA 3

3.2 Dataset M2 - USMLE com gabarito 3

3.3 Escopo efetivamente executado 3

4 Fundamentação teórica **4**

5 Materiais e organização dos arquivos **4**

6 Metodologia **5**

6.1 Curadoria das questões abertas 5

6.2 Curadoria das questões de múltipla escolha 5

6.3 Modelos avaliados 6

6.4 Critérios de avaliação 6

6.5 Justificativa metodológica 7

7 Resultados **7**

7.1 Panorama quantitativo do material produzido 7

7.2 Médias por modelo 8

7.3 Interpretação dos resultados 8

7.4 Exemplos representativos 8

8 Discussão **9**

9 Estrutura recomendada para o repositório individual **10**

10 Conclusão **11**

1 Introdução

A Atividade Avaliativa 1 da disciplina de Tópicos Avançados em Engenharia de Software e SI I teve como foco a curadoria de datasets e o contato inicial com inferência utilizando Modelos de Linguagem de Grande Porte (LLMs) no contexto de domínios críticos. No domínio médico, a proposta envolveu duas frentes complementares: a organização e anotação de um subconjunto de questões abertas do benchmark K-QA e a curadoria de um subconjunto de questões de múltipla escolha do conjunto USMLE com gabarito.

Neste relatório são documentadas as atividades individuais realizadas por Gilson Inácio da Silva no domínio médico, correspondentes às questões abertas de identificadores oficiais 86 a 100 e às questões de múltipla escolha de identificadores oficiais 136 a 162. O trabalho buscou manter rastreabilidade entre fontes, justificativas clínicas, respostas geradas por modelos e critérios de avaliação, produzindo um conjunto de artefatos reproduzíveis organizado em planilhas CSV, workbook consolidado e script de processamento.

Do ponto de vista conceitual, o trabalho também procurou respeitar uma preocupação central do uso de LLMs em saúde: respostas linguisticamente parecidas com uma referência não são, necessariamente, respostas clinicamente corretas ou seguras. Em medicina, pequenas mudanças semânticas – por exemplo, afirmar ou negar uma conduta, omitir um sinal de alerta ou suavizar uma contraindicação – podem ter impacto direto sobre o risco clínico. Por essa razão, a avaliação adotada neste recorte individual privilegiou critérios supervisionados de correção clínica, completude, alinhamento com a resposta especialista, segurança e clareza.

2 Objetivos

2.1 Objetivo geral

Avaliar, de forma documentada e reproduzível, o comportamento de três modelos de linguagem em questões médicas abertas atribuídas ao discente, além de organizar e justificar a curadoria do subconjunto individual de questões de múltipla escolha.

2.2 Objetivos específicos

- Curar as questões abertas 86–100, registrando dificuldade, especialidade, referência utilizada e observações do curador.
- Curar as questões de múltipla escolha 136–162, registrando gabarito, especialidade, dificuldade, referência, explicação e notas do curador.

- Submeter as 15 questões abertas a três modelos de linguagem selecionados.
- Comparar cada resposta gerada com a resposta padrão-ouro do dataset K-QA.
- Atribuir notas por critério clínico e produzir uma interpretação qualitativa dos resultados.
- Consolidar os resultados em arquivos reutilizáveis para composição do repositório individual e posterior integração com a entrega final da atividade.

3 Bases de dados e escopo individual

3.1 Dataset M1 - K-QA

O subconjunto de questões abertas foi extraído do benchmark K-QA, descrito no artigo *K-QA: A Real World Medical Q&A Benchmark*. Esse dataset apresenta perguntas médicas de linguagem natural acompanhadas de uma resposta livre de especialista (*free-form answer*) e de uma decomposição explícita em elementos essenciais (*Must Have*) e elementos desejáveis (*Nice to Have*). Essa estrutura foi particularmente útil neste trabalho porque permitiu avaliar as respostas dos modelos não apenas por proximidade textual, mas também por cobertura de conteúdo clinicamente relevante.

No recorte individual deste relatório, foram utilizadas 15 questões abertas, correspondentes aos identificadores 86 a 100.

3.2 Dataset M2 - USMLE com gabarito

O subconjunto de questões de múltipla escolha foi organizado a partir da base USMLE disponibilizada para a atividade. Neste relatório foram curadas 27 questões, correspondentes aos identificadores oficiais 136 a 162. Para cada item foram registrados enunciado, alternativas, gabarito, especialidade, nível de dificuldade, referência clínica, explicação e notas do curador.

3.3 Escopo efetivamente executado

É importante explicitar que, neste recorte individual, a **inferência com LLMs e a avaliação quantitativa estruturada foram realizadas sobre as questões abertas**. As questões de múltipla escolha foram **integralmente curadas e preparadas**, mas não receberam, neste workbook individual, um bloco adicional de inferência automática com cálculo de acurácia. Essa decisão não foi omissão metodológica; ela reflete exatamente os

artefatos efetivamente produzidos e preserva a rastreabilidade entre o que foi executado e o que está documentado.

4 Fundamentação teórica

Dois eixos teóricos orientaram a execução da atividade. O primeiro foi o próprio desenho do K-QA, que foi concebido para avaliação mais realista de perguntas médicas abertas, com foco em respostas longas e clinicamente densas. Em vez de tratar a referência como uma única frase-alvo, o benchmark separa componentes obrigatórios e desejáveis, permitindo observar lacunas, omissões e extrapolações.

O segundo eixo foi o artigo *Large Language Models in Medicine*, utilizado como base complementar para a discussão metodológica. De modo consistente com essa literatura, este trabalho assume que LLMs podem ser úteis como ferramenta assistiva de organização e síntese, mas que, em domínio médico, sua avaliação precisa ser supervisionada por critérios mais fortes do que simples sobreposição de palavras. Isso justifica a opção por um protocolo manual e estruturado de avaliação, em vez de depender exclusivamente de BLEU, ROUGE ou outras métricas lexicais.

Assim, embora métricas automáticas de similaridade possam ser úteis em certas tarefas, o procedimento adotado aqui foi deliberadamente conservador: comparar a saída dos modelos com a resposta especialista e pontuá-la segundo critérios explicitamente relacionados à segurança e à qualidade clínica.

5 Materiais e organização dos arquivos

A estrutura final de trabalho ficou organizada da seguinte forma:

```
Top-Avanc-EngSoft-SI-I-26-1-Gilson-Inacio-Silva-Med-Ativ1/
|-- README.md
|-- data/
|   |-- dataset.json
|   |-- questions_w_answers.jsonl
|   `-- usmle_questions.json
|-- scripts/
|   `-- processar.py
|-- outputs/
|   |-- curadoria_abertas.csv
|   |-- curadoria_mc.csv
|   |-- respostas_llms.csv
```

```
|   |-- avaliacao_llms.csv
|   `-- Workbook_Equipe2_Medicina_Atividade1_Gilson_Inacio_da_Silva.xlsx
`-- relatorio/
    |-- Relatorio_Individual_Gilson_Inacio_Silva_Atividade1.pdf
    `-- Relatorio_Individual_Gilson_Inacio_Silva_Atividade1.docx
```

Os arquivos centrais utilizados neste relatório são o workbook consolidado e os quatro CSVs de saída:

- `curadoria_abertas.csv`: curadoria das questões abertas 86–100;
- `curadoria_mc.csv`: curadoria das questões de múltipla escolha 136–162;
- `respostas_llms.csv`: registro das respostas dos três modelos para as questões abertas;
- `avaliacao_llms.csv`: avaliação detalhada por critério e por modelo.

Os CSVs já representam o núcleo executado da atividade individual. Portanto, não há necessidade de acrescentar seções artificiais com métricas não calculadas ou artefatos não produzidos. O que foi incluído neste relatório corresponde ao que foi efetivamente gerado, consolidado e revisado nas planilhas finais.

6 Metodologia

6.1 Curadoria das questões abertas

Para cada uma das 15 questões abertas do lote individual, foram mantidos ou organizados os seguintes campos: identificador oficial, pergunta, resposta padrão-ouro, itens obrigatórios (*must have*), itens desejáveis (*nice to have*), fonte clínica, dificuldade, especialidade, referência utilizada e nota do curador.

A curadoria das abertas teve dois objetivos práticos. Primeiro, facilitar a interpretação clínica mínima necessária para ler a resposta padrão-ouro. Segundo, explicitar, na coluna `curator_notes`, o foco central da questão de forma curta e operacional, permitindo rastrear rapidamente o que deveria ser observado nas respostas dos LLMs.

6.2 Curadoria das questões de múltipla escolha

As 27 questões de múltipla escolha foram curadas de forma independente das abertas. Para cada item foram organizados:

- identificadores da questão;
- enunciado e alternativas;
- gabarito registrado na base;
- nível de dificuldade;
- especialidade;
- referência clínica utilizada;
- explicação técnica da alternativa correta;
- *curator notes*.

Essa curadoria serviu como base documental do lote de múltipla escolha e como preparação para eventual replicação posterior, seja pela equipe, seja em uma etapa futura com inferência automática.

6.3 Modelos avaliados

As questões abertas foram submetidas a três modelos:

1. GPT-5.4 Thinking
2. Claude 4.6 Sonnet
3. Gemini 3.0

As respostas foram registradas integralmente no arquivo `respostas_llms.csv` e no workbook final.

6.4 Critérios de avaliação

Cada resposta gerada foi avaliada segundo cinco critérios, todos em escala de 0 a 2:

- **Clinical Correctness**: correção clínica da resposta;
- **Completeness**: nível de cobertura do conteúdo essencial;
- **Alignment with Gold Answer**: proximidade semântica e conceitual com a resposta especialista;
- **Safety**: grau de segurança clínica da orientação fornecida;

- **Clarity**: clareza e legibilidade da resposta.

A soma gera uma nota total de 0 a 10 por resposta. Como foram 15 perguntas e 3 modelos, o arquivo final de avaliação contém 45 linhas.

6.5 Justificativa metodológica

A escolha por essa rubrica foi intencional. Embora a formulação mais ampla da atividade admita métricas como BLEU, ROUGE, F1, BERTScore, acurácia, embeddings e LLM-judge, neste recorte individual foi adotado um processo manual supervisionado por critérios clínicos, por três razões principais:

1. o domínio é crítico e exige penalização explícita de respostas inseguras;
2. o lote individual é pequeno, o que torna viável a avaliação criteriosa resposta a resposta;
3. o próprio K-QA fornece uma estrutura de referência rica (*gold answer*, *must have*, *nice to have*), favorecendo avaliação supervisionada em vez de simples sobreposição lexical.

7 Resultados

7.1 Panorama quantitativo do material produzido

O trabalho individual gerou os seguintes volumes:

- 15 questões abertas curadas;
- 27 questões de múltipla escolha curadas;
- 45 respostas de LLMs registradas (15 questões $\times$ 3 modelos);
- 45 linhas de avaliação estruturada.

Quanto à distribuição de dificuldade:

- **Questões abertas**: 11 classificadas como *Easy* e 4 como *Medium*;
- **Questões de múltipla escolha**: 5 *Easy*, 18 *Medium* e 4 *Hard*.

7.2 Médias por modelo

A Tabela 1 resume as médias obtidas por modelo na avaliação das questões abertas.

Tabela 1: Médias por critério e nota total por modelo

Modelo	**CC**	**Comp.**	**Align.**	**Safety**	**Clarity**	**Total**
GPT-5.4 Thinking	2.00	1.67	2.00	2.00	2.00	9.67
Claude 4.6 Sonnet	1.87	1.87	1.80	1.93	2.00	9.47
Gemini 3.0	1.93	1.73	1.80	2.00	2.00	9.47

A Tabela 2 mostra a distribuição de notas máximas, intermediárias e mais baixas por modelo.

Tabela 2: Distribuição de notas por modelo

Modelo	**Questões**	**Nota 10**	**Nota 9**	**Nota $\leq$ 8**
GPT-5.4 Thinking	15	10	5	0
Claude 4.6 Sonnet	15	10	3	2
Gemini 3.0	15	9	5	1

7.3 Interpretação dos resultados

Os resultados mostram um padrão relativamente claro. O GPT-5.4 Thinking obteve a maior média total (9.67/10), sem nenhuma ocorrência abaixo de 9. Em termos práticos, esse comportamento sugere maior consistência global em correção clínica, segurança e alinhamento com a resposta especialista, ainda que algumas respostas tenham sido deliberadamente mais concisas, o que explica sua média de completude um pouco menor.

Claude 4.6 Sonnet e Gemini 3.0 apresentaram médias totais idênticas (9.47/10), mas por trajetórias qualitativamente um pouco diferentes. O Claude foi, em vários casos, mais detalhado e interpretativo, o que favoreceu completude em parte do lote; por outro lado, algumas formulações se afastaram do foco exato da resposta padrão-ouro. O Gemini, por sua vez, manteve boa segurança e boa clareza, mas em alguns casos apresentou respostas mais genéricas, menos aderentes ao núcleo específico da pergunta.

7.4 Exemplos representativos

Três casos foram particularmente úteis para discussão:

- **Questão 87 (fluoxetina / interrupção do tratamento):** o Claude recebeu nota 7 porque sugeriu que, em alguns cenários, a suspensão abrupta poderia ser tolerada, enfraquecendo a orientação principal de evitar interrupção súbita sem supervisão médica.
- **Questão 88 (distensão muscular):** o Claude recebeu nota 8 por indicar um horizonte temporal mais curto para quadros graves, enquanto a resposta especialista admitia recuperação ao longo de meses. O GPT também ficou abaixo de 10 por ser mais conciso e não detalhar medidas de alívio e fatores de recuperação.
- **Questão 91 (uso de Tinactin):** o Gemini recebeu nota 7 porque, embora seguro, concentrou-se mais em cautelas diagnósticas gerais do que nas indicações mais típicas, esperadas e específicas do padrão-ouro para infecções fúngicas superficiais.

Esses exemplos mostram que a maior parte das diferenças entre os modelos, neste lote, não veio de erros grosseiros, mas de nuances importantes para medicina: grau de especificidade, prudência terapêutica, cobertura de sinais de alerta e aderência ao foco clínico central.

8 Discussão

Os resultados deste recorte individual reforçam uma hipótese importante para aplicações de LLMs em saúde: **uma resposta pode ser linguisticamente boa e ainda assim perder valor clínico se errar o foco, suavizar uma contraindicação, omitir um sinal de alerta ou deslocar a recomendação principal**. Foi justamente por isso que a estratégia adotada neste trabalho não dependeu de similaridade lexical como critério principal.

A combinação entre resposta padrão-ouro, campos *must have* e *nice to have*, observações por questão e rubrica supervisionada permitiu uma avaliação mais alinhada com a natureza do problema. Em vez de perguntar apenas "quão parecido" um texto é do outro, a pergunta metodológica passou a ser: *a resposta está clinicamente correta, cobre o essencial, permanece segura e continua alinhada ao que o especialista considerou adequado?*

Essa abordagem também dialoga com a literatura atual sobre LLMs em medicina. Modelos podem ser bastante úteis na geração de respostas organizadas, claras e semanticamente próximas da referência. Entretanto, a utilidade prática depende de salvaguardas. Neste trabalho, as salvaguardas adotadas foram explícitas: avaliação resposta a resposta, confronto com padrão-ouro e atribuição de nota por critério clínico.

Outro ponto importante é que o lote de múltipla escolha, embora não tenha sido inferido automaticamente neste workbook individual, foi integralmente preparado e curado. Isso não é secundário. Em avaliações futuras, essa curadoria já deixa estruturados o gabarito, a justificativa clínica e os metadados necessários para experimentos com acurácia, erro por especialidade e comparação entre modelos em tarefas objetivas.

Como limitações do presente relatório, cabe registrar que:

- não foram calculadas métricas automáticas como BLEU, ROUGE, BERTScore ou similaridade por embeddings neste recorte individual;
- custos de tokens, latência e eventuais efeitos de quantização não foram medidos;
- a análise está concentrada no lote individual do discente e, portanto, não representa todo o domínio médico da turma.

Essas limitações não invalidam o resultado; apenas delimitam seu escopo. O que este relatório oferece é um retrato fiel, auditável e reproduzível do que foi efetivamente executado.

9 Estrutura recomendada para o repositório individual

Considerando os artefatos produzidos, a estrutura recomendada para o repositório individual é:

```
Top-Avanc-EngSoft-SI-I-26-1-Gilson-Inacio-Silva-Med-Ativ1/
|-- README.md
|-- data/
|   |-- dataset.json
|   |-- questions_w_answers.jsonl
|   `-- usmle_questions.json
|-- scripts/
|   `-- processar.py
|-- outputs/
|   |-- curadoria_abertas.csv
|   |-- curadoria_mc.csv
|   |-- respostas_llms.csv
|   |-- avaliacao_llms.csv
|   `-- Workbook_Equipe2_Medicina_Atividade1_Gilson_Inacio_da_Silva.xlsx
`-- relatorio/
```

```
|-- Relatorio_Individual_Gilson_Inacio_Silva_Atividade1.pdf
`-- Relatorio_Individual_Gilson_Inacio_Silva_Atividade1.docx
```

Essa organização preserva separação entre dados brutos, script, saídas e documentação final.

10 Conclusão

Este relatório documentou a execução individual da Atividade Avaliativa 1 no domínio médico para o lote composto pelas questões abertas 86–100 e pelas questões de múltipla escolha 136–162. O trabalho resultou em quatro entregáveis centrais: curadoria das abertas, curadoria das múltipla escolha, registro das respostas dos três LLMs e avaliação estruturada das respostas abertas contra o padrão-ouro especialista.

No subconjunto de perguntas abertas, o GPT-5.4 Thinking apresentou a maior média geral (9.67/10), seguido por Claude 4.6 Sonnet e Gemini 3.0, ambos com 9.47/10. Apesar do bom desempenho geral dos três modelos, as diferenças encontradas foram pedagogicamente relevantes: algumas respostas perderam nota por excesso de generalidade, outras por reduzir em excesso a prudência clínica, e outras por se afastar do foco exato esperado pela resposta especialista.

Do ponto de vista metodológico, o principal resultado deste trabalho foi mostrar que, para um lote médico pequeno e crítico, uma avaliação supervisionada por critérios clínicos foi mais defensável do que depender exclusivamente de métricas lexicais. Isso torna o material produzido mais útil tanto para prestação de contas acadêmica quanto para reaproveitamento posterior em experimentos maiores.

Declaração de autoria

Declaro que este relatório descreve a parte individual desenvolvida por mim no âmbito da Atividade Avaliativa 1, incluindo organização dos dados, curadoria, registro das respostas dos modelos, avaliação das questões abertas e consolidação dos arquivos finais.

Referências

[1] UNIVERSIDADE FEDERAL DE SERGIPE. *Atividade – Tópicos Avançados em Engenharia de Software e SI I: Atividade 1*. Documento disponibilizado na disciplina. 2026.

[2] BENCHIMOL-ELKAIM, A. et al. *K-QA: A Real World Medical Q&A Benchmark*. BioNLP, 2024.

[3] *Large Language Models in Medicine*. Documento de apoio teórico utilizado na disciplina.

[4] UPTODATE. Base de apoio clínico utilizada nas referências por questão. Acesso conforme links registrados nas planilhas de curadoria e respostas.